

BL5-v4-PAM 主结果封口路线与后续规划

文档性质：项目路线决策文档

核心决策：当前不进入 BL6，不继续堆叠 BL5 新架构，优先将 BL5-v4-PAM 作为阶段主结果封口。

依据来源：BL0b / BL5-v4-NoPAM / BL5-v4-PAM / BL5-v4-PAM-shuffle-control 的完整实验验证链，以及 per-sgRNA、per-PAM、分层指标和 paired probability delta 分析。

合规声明：本文档遵守 AGENTS.md 约束，所有指标同时报告 AUROC 与 AUPRC，test 评估均基于 `best.pt` checkpoint。

0. 决策总览（一句话版）

当前不要开 BL6。当前不要继续堆 BL5 新架构。优先封口 BL5-v4-PAM：

第一优先级（不需要训练，直接增强面对老师提问的能力）： 1. per-sgRNA 分析 2. per-PAM motif 分析 3. bootstrap confidence interval 4. threshold / top-k operating point 表

第二优先级（小型 baseline，排除质疑）： 5. kNN / nearest-neighbor baseline 6. PAM-only baseline

第三优先级（解释性扰动）： 7. in-silico perturbation

第四优先级（训练稳定性）： 8. BL5-v4-PAM 多 seed 重复

然后视老师要求补 BL4-full 作为路线完整性 baseline。

最后再考虑 BL6。

1. 当前科学现状（基于已完成的实验）

1.0 为什么 Accuracy 不能做主指标？为什么 AUROC 不够？

在讲实验结果之前，必须先理解一个关键背景：**我们的数据极度不平衡**。在 954,326 条 test 样本中，只有

3,057 个是 observed_positive (约 0.32%)，其余 951,269 个都是 unobserved_candidate。


这意味着什么？意味着一个"傻子模型"——把全部样本都预测成 0 (unobserved_candidate) ——它的 **Accuracy 已经高达 99.68%**。所以如果你只报告 Accuracy，老师会觉得"这模型不是跟瞎猜差不多吗？"

那 AUROC 呢？AUROC 衡量的是"随机抽一个 positive 和一个 negative，模型把 positive 排在 negative 前面的概率"。在极度不平衡的数据上，AUROC 很容易虚高，因为 negative 样本实在太多了，模型只要能把大部分 negative 排在后面，AUROC 就会很好看。

所以我们需要 **AUPRC** (Area Under Precision-Recall Curve)。它问的是另一个更实际的问题：**在模型打分最高的那些候选位点里，有多少是真正的 observed_positive？** 这和实验室的真实场景完全对应——你不能测 95 万个位点，你只能测前 1000 个，你需要这前 1000 个里 true positive 越多越好。

AUROC vs AUPRC:

AUROC: global separation



Question: Is a random observed_positive ranked above a random unobserved_candidate?

Good for global ranking.

Because observed_positive is rare, A

这张图怎么读（小白版）：

这张图用红蓝点告诉我们 AUROC 和 AUPRC 到底在问什么问题。

- **左图 AUROC：全局分离。**想象你把所有样本铺开，红点（observed_positive）应该整体偏上，蓝点（unobserved_candidate）应该整体偏下。AUROC 问的是："随机抓一个红点和蓝点，红点分数比蓝点高的概率是多少？" 这很好，但它是个"全局"指标，不 care 你具体 inspected 了哪些。
- **右图 AUPRC：top-ranked 实用性。**想象你把所有样本按模型打分从高到低排成一列。AUPRC 问的是："只看最前面的这一截（top predictions inspected），里面红点占多大比例？" 这才是实验室关心的——预算有限，只能测前 k 个，前 k 个里 true positive 的比例就是 Precision@k。

底部那句话最关键："Because observed_positive is rare, AUPRC is the primary metric for practical screening." 因为 positive 很稀有，所以 **AUPRC 才是实际筛查场景下的主指标**。这也是为什么我们整篇文档都把 AUPRC 放在比 AUROC 更重要的位置。

1.1 四模型核心指标（formal BL5 split, test set）

模型	AUROC	AUPRC	相对 BL0b AUPRC Δ
BL0b-on-BL5split	0.8578	0.2957	—
BL5-v4-NoPAM-control	0.9841	0.5024	+0.2067
BL5-v4-PAM	0.9842	0.5313	+0.2356
BL5-v4-PAM-shuffle-control	0.6697	0.1389	-0.1568

关键数字： - NoPAM - BL0b = +0.2067：BL5-v4 框架（LearnableRun + concat MLP）本身的巨大增益。 - PAM - NoPAM = +0.0289：正确 PAM Encoder 的额外增益。 - PAM - Shuffle = +0.3924：正确 PAM vs 随机 PAM 的鸿沟。 - Shuffle - BL0b = -0.1568：Shuffle 控制甚至比纯 RNA-FM baseline 还差。

AUROC

0.4

0.6


0.8


1.0

0.8578

A

0





标准学术对比图。绿色 (PAM, AUPRC=0.5313) 全面包络橙色 (NoPAM, 0.5024) ; 红色 (Shuffle, 0.1389) 在 Recall $\approx$ 0.12 处垂直掉落至 0, 然后贴着 X 轴走, 是典型的模型失效曲线。

PAM ablation design: wh

BL0b-on-BL5split	RNA-FM CLS	
BL5-v4-NoPAM-control	RNA-FM CLS	 +0.
BL5-v4-PAM	RNA-FM CLS	 +0.
BL5-v4-PAM-shuffle-control	RNA-FM CLS	 -0.



same formal split

这张图怎么读（小白版）：

这张图用"输入信号 → 输出指标"的方式，把四个模型之间的差异讲得一清二楚。你可以把它理解成四个不同配置的"黑箱实验"，唯一变量就是模型能"看到"哪些信息。


- **第一行 BL0b（蓝色）**：模型只看 **RNA-FM CLS**（RNA-FM 预训练模型输出的 640 维向量），没有 Run block，没有 PAM block。这是最简单的 RNA-FM baseline，AUPRC = 0.2957。你可以把它理解为"只有序列上下文，没有任何工程先验"。
- **第二行 NoPAM（橙色）**：在 BL0b 基础上加了 **LearnableRun**（positions 1-20 的连续错配状态编码），但仍然没有 PAM Encoder。AUPRC 跳到 0.5024，增益 +0.2067。这说明：**Run 特征（连续错配状态）本身就是极强的信号**，它让模型从"序列上下文"升级到了"知道哪里连续错配"。
- **第三行 PAM（绿色）**：在 NoPAM 基础上再加 **Correct PAM Encoder**（positions 21-23）。AUPRC 再跳到 0.5313，增益 +0.0289。这说明：**正确的 PAM 信息提供了额外的、虽然不大但是真实的增益**。注意这里写的不是"PAM 本身"，而是"Correct PAM"——因为下一个控制证明，如果 PAM 错了，结果会崩。
- **第四行 Shuffle（红色）**：和 PAM 完全一样的架构，但 PAM 输入被**随机打乱**（Sample A 拿到了 Sample B 的 PAM）。AUPRC 暴跌到 0.1389，比 BL0b 还差。这说明：**PAM Encoder 不是来凑参数的，它极度依赖"正确的 PAM 与样本对应关系"**。如果对应关系错了，模型会被严重误导。

底部三个图标是这份报告最重要的"质量控制声明"： - same formal split（四个模型用完全一样的 train/val/test 划分） - same labels（标签完全一致） - best.pt evaluation（全部用验证集 AUPRC 最佳时的 checkpoint 评估，不用 last checkpoint）

1.2 Test Cohort 核验

- test_samples = 954,326
- test_positive (observed_positive) = 3,057
- test_negative (unobserved_candidate) = 951,269
- positive_rate = 0.003203 (~0.32%)
- 四模型共用同一 test set, sample_index 完全对齐。

Mean predicted



Ideal behavior: high mean_prob_po

label=0 means unobs

这张图怎么读（小白版）：

这张图告诉我们，一个"好模型"应该长什么样。

- **左图（红点：observed_positive）**：这些是在实验里真的被检测到有切割的位点。理想情况下，模型应该给它们较高的预测概率。图中红点的平均概率大约在 0.7~0.9 之间，分布相对集中，说明模型对 true positive 有自信。
- **右图（蓝点：unobserved_candidate）**：这些是实验里没有检测到切割的位点（注意：label=0 不代表安全，只是"没被检测到"）。理想情况下，模型应该给它们较低的预测概率。图中蓝点大量挤在 0 附近，说明模型对 negative 是"不确定/不看好"的。
- **中间的 Separation gap（分离间隙）**：左图红点的均值（~0.8）和右图蓝点的均值（~0.05）之间存在巨大鸿沟。这个鸿沟越大，模型区分能力越强。

底部还有一句重要的话："label=0 means unobserved_candidate, not verified safe." 这对应 AGENTS.md 的术语规范——我们不用 "negative" 或 "safe"，只用 "unobserved_candidate"。因为没被检测到切割，可能只是实验灵敏度不够，不代表这个位点绝对安全。

1.3 已有的证据链

当前实验已经形成了从 **baseline** → **框架增益** → **PAM 特异性** → **机制解释** 的完整闭环：

BL0b (0.296)
↓ +0.207
NoPAM (0.502) ← BL5-v4 框架增益 (LearnableRun + MLP)
↓ +0.029
PAM (0.531) ← 正确 PAM 额外增益
↑
Shuffle (0.139) ← 打乱 PAM 后崩溃，证明增益依赖正确对应关系

分层证据： - **NGG-only**（86% 样本，positive rate 0.29%）：Shuffle AUPRC ≈ 0.004（几乎失效），PAM AUPRC = 0.356（主战场）。 - **non-NGG-only**（14% 样本，positive rate 0.53%）：所有模型都不错，Shuffle AUPRC = 0.605。





Figure 5 reading guide: s



Main question: does PAM still help inside

这张图怎么读（小白版）：

这张图回答了老师最可能问的一个问题："PAM 的提升是不是主要来自 non-NGG 的 shortcut？"

我们先把 test set 切成三块，然后分别看四模型的 AUPRC：

- **左图 All test（全部样本）**：整体情况和 Fig 1 一致——PAM (0.531) > NoPAM (0.502) > BL0b (0.296) > Shuffle (0.139)。
- **中图 NGG-only（只保留 PAM 为 NGG 的样本，占 86%）**：这是数据的大头，也是 hardest case (positive rate 只有 0.29%)。关键发现：
 - BL0b 在 NGG-only 上几乎失效 (AUPRC = 0.114)，说明纯 RNA-FM 在 NGG 场景下非常吃力。
 - NoPAM 提升到 0.324，PAM 进一步提升到 0.356——**PAM 在 NGG-only 上仍然有明确的增益**，这不是 non-NGG shortcut。
 - Shuffle 崩到 0.004，几乎为 0。
- **右图 non-NGG-only（只保留 non-NGG 样本，占 14%）**：这是相对容易的子集 (positive rate 0.53%)。所有模型表现都不错，Shuffle 也有 0.605。这说明 non-NGG 位点本身可能更容易判别，但它们不是 **PAM 模型优势的主要来源**（因为所有模型在这里都不错）。


底部的问题直接点出了这张图的核心叙事："does PAM still help inside NGG-only, or is the gain dominated by non-NGG shortcut?" 答案是：**PAM 在 NGG-only 上仍然显著有帮助 (0.324 → 0.356)**，提升不是被 **non-NGG shortcut 主导的**。

右侧小字提醒："Subsets are evaluation slices, not different model types." 意思是这三组图是**把同一个模型在不同子集上重新评估**，而不是训练了三个不同的模型。这是分层分析的关键——保证公平对比。

- **Paired delta**：PAM vs Shuffle 时，Observed Positive median $\Delta = +0.1523$ ，Unobserved Candidate median $\Delta = -0.1003$ ——正确 PAM **选择性抬高 positive、压低 negative**，不是全员灌水。

Probability Delta

0.15
0.10
0.05
0.00
-0.05
-0.10



左图：PAM vs NoPAM 的 delta 很小（median ≈ -0.01 ），说明正确 PAM 是在强 baseline 上的微调。

右图：PAM vs Shuffle 的 delta 巨大，Observed Positive median = +0.1523，Unobserved Candidate median = -0.1003，证明正确 PAM 是选择性增强而非全员灌水。

2. 为什么现在不进 BL6 / 不继续堆 BL5 新架构

2.1 为什么不进 BL6

BL6 的定义是"Cross-View Attention + Gated Fusion + 多层交互 + 不确定性感知"。在当前节点推进 BL6 有以下风险：

风险	说明
证据不足	当前尚未验证"简单拼接（BL4-full）是否优于单一视角"。BL5-3 才是 Cross-Attn + Gated，BL6 在此基础上再加多层交互，属于"在尚未夯实的地基上盖楼"。
解释链断裂	老师追问"BL6 比 BL5-3 好多少？"时，如果 BL5-3 本身还没有在 CCLMoff formal split 上跑完，无法回答。
资源错配	BL6 参数量更大、训练更慢、调参空间更广。在 BL5-v4-PAM 的封口工作尚未完成时，进 BL6 会导致"最强模型的故事讲不清楚，新模型的故事又讲不扎实"。
路线违规	AGENTS.md 第 18 章明确禁止跳步："跳过 BL4 直接做 BL5"和"跳过 BL3-gradient 直接做 BL4-full"都是禁止行为。BL6 是 BL5-3 之上的增强，必须先有稳定的 BL5-3/BL5-v4 主结果。

2.2 为什么不继续堆 BL5 新架构

BL5 系列的核心科学问题是"动态融合是否优于简单拼接"。当前 BL5-v4-PAM 已经用 **simple concat** 达到了 AUPRC=0.5313。如果继续在同一代码基上尝试 BL5-1 (Cross-Attn)、BL5-2 (Gated)、BL5-3 (Full)，可能出现：


- **收益递减**：从 0.5313 提升到 0.55+ 的边际收益，远不如先把 0.5313 **讲稳、讲透**。
- **叙事混乱**：组会上老师问"你当前的主结果到底是哪个？"，如果同时有 v4-PAM、v5-

CrossAttn、v6-...，主线不清晰。

- **实验债务：**每增加一个子版本，就需要配套的 NoPAM/shuffle/per-sgRNA 分析，工作量指数增长。

结论：BL5-v4-PAM 的 simple concat 已经很强。当前最急迫的不是继续追新模型，而是把现在这个结果从"看起来赢了"推进到"经得住追问"。


AUPRC Delta



最推荐组会主图：绿柱 vs 红柱的对比极具冲击力。NoPAM 比 BL0b 高 +0.2067，PAM 比 NoPAM 再高 +0.0289，而 Shuffle 比 NoPAM 低 -0.3635。说明 PAM 的价值极度依赖"正确的 PAM-样本对应"，而不是单纯多了几层参数。

Correct PAM vs

NoPAM



The model predicts without explicit PAM positions 21-23.

NoPAM AUPRC = 0.502

Co

RNA-FM
sequence con

Run feature
positions 1-

Correct PA
positions 21

The m
PAM-sa

Correct

Correct con

这张图怎么读（小白版）：


这张图用三列流程图，把"PAM 到底在干什么"讲得连非技术背景的人都能看懂。

- **左列 NoPAM（橙色）**：模型收到两个输入——RNA-FM sequence context（序列上下文）和 Run features（连续错配状态，positions 1-20）。PAM 这一块用虚线框标着"PAM not provided"，意思是模型**不知道** positions 21-23 是什么。它只能凭前 20 个位置的序列和错配模式来猜。结果 AUPRC = 0.502。
- **中列 Correct PAM（绿色）**：和 NoPAM 完全一样的前两个输入，但多了一个实线框的 **Correct PAM**（positions 21-23）。这个 PAM 是**真实的、和当前样本一一对应的**。模型现在知道了"这个 sgRNA 的 PAM 是 NGG"，结果 AUPRC 提升到 0.531。
- **右列 Shuffled PAM（红色）**：架构和中列完全一样，也收到了 PAM 输入，但**这个 PAM 是从另一个随机样本偷来的**。例如 Sample A 的序列配上了 Sample B 的 PAM。PAM 分布的统计特征没变（还是那些 AGG/TGG/GGG），但**对应关系被打破了**。结果 AUPRC 暴跌到 0.139。

底部结论只有一句话，但分量极重："Correct correspondence matters." 正确的对应关系才是最重要的。

PAM Encoder 不是来堆参数的，它是来提供"这个 PAM 和这个 sgRNA 是一对"的生物学信号的。信号对了，模型受益；信号错了，模型被严重误导。

BL5-v4 PAM co



Disclose PAM shortcut

这张图怎么读（小白版）：

这张图是整篇文档的"核心叙事图"，适合放在组会 PPT 的最后一页或结论页。它把从 BL0b 到 PAM 的完整递进关系画成了流程。

- **起点 BL0b**：只用一个蓝色方块表示"RNA-FM only"，AUPRC = 0.2957。这是我们的起跑线。
- **第一步 +LearnableRun + v4 classifier → NoPAM**：加了橙色模块（Run 特征 + 分类器），AUPRC 跳到 0.5024，增益 +0.2067。右侧解读第一条："NoPAM already gives a strong v4 framework." 这说明 BL5-v4 框架本身（LearnableRun + MLP）就是巨大的进步来源。
- **第二步 +Correct PAM Encoder → PAM**：加了绿色模块（Correct PAM），AUPRC 再跳到 0.5313，增益 +0.0289。右侧解读第二条："Correct PAM adds a modest but real gain." 这个增益不大，但是真实存在的。
- **红色下箭头 Shuffle PAM correspondence → Shuffle control**：从 PAM 往下拐了一个红箭头，标注 "-0.3924"，指向 Shuffle control（AUPRC = 0.1389）。右侧解读第三条："Shuffled PAM severely misleads the model." 打乱的 PAM 不仅没帮助，反而严重误导了模型。

底部黄色警告框也很重要："Disclose PAM shortcut risk and specify PAM definition: positions 21-23." 这提醒我们：在汇报时必须明确告诉老师，PAM 是指 positions 21-23，而且我们要主动披露"PAM shortcut 风险"——即模型可能过度依赖 PAM 而忽视序列上下文。这种主动披露反而会增强可信度。

3. Phase 1：BL5-v4-PAM 封口（按优先级分四层）

第一优先级：不需要训练的验证分析

这一步最划算，直接增强你面对老师提问的能力。所有分析直接基于已有的
test_predictions.csv 和 summary.json，不需要 GPU 训练。

3.1 per-sgRNA 分析

回答老师可能会问的： - 是不是只在少数几个 sgRNA 上赢？ - 有没有某些 sgRNA 特别拖后腿？ - BL5-v4-PAM 相比 NoPAM 的提升是不是普遍存在？

做什么： - 在 72 个 test sgRNA 上分别计算 AUPRC、AUROC、Precision、Recall。 - 计算 **PAM – NoPAM** 的 per-sgRNA AUPRC delta。 - 计算 **PAM – Shuffle** 的 per-sgRNA AUPRC delta。 - 记录每个 sgRNA_type 的 samples 数、observed_positive 数、positive_rate。 - 画出分布：per-sgRNA AUPRC histogram、PAM–NoPAM delta scatter（按样本数加权）、worst-5 / best-5 sgRNA 表格。

为什么重要： - 整体 AUPRC 高不够，最好能说明提升不是集中在一两个 sgRNA 上。 - 如果 72 个 sgRNA 中有 60 个 PAM > NoPAM，叙事是"普遍提升"；如果只有 15 个，叙事需要调整。

预期产出： - results/per_sgrna_metrics_with_pam.csv - results/per_sgrna_metrics_with_pam.md - results/figures/bl5_accuracy/per_sgrna_delta_plot.png/pdf

关键检查项： - PAM > NoPAM 的 sgRNA 占比 - worst-5 sgRNA 的 AUPRC、样本数、positive count - per-sgRNA AUPRC 与样本数 / positive rate 的相关性

【待插入】左图：72 个 test sgRNA 的 AUPRC 分布直方图；右图：PAM – NoPAM per-sgRNA AUPRC delta 的 scatter plot（点大小按 sgRNA 样本数加权）。需要能看出提升是否普遍分布在多数 sgRNA 上，而非集中在少数几个。

3.2 per-PAM motif 分析

回答老师可能会问的： - PAM Encoder 是不是只靠 NGG / non-NGG shortcut？ - 哪些 PAM motif 贡献最大？ - AGG / TGG / GGG / CGG 内部表现是否一致？

做什么： - 把 test set 按 PAM motif 分组（AGG, TGG, GGG, CGG, non-NGG, rare PAM）。 - 每组计算：samples、observed_positive、positive_ratio、mean probability、AUPRC、AUROC。 - 对比四模型（BL0b / NoPAM / PAM / Shuffle）在各 PAM 组上的 AUPRC。 - 画出 PAM-group 柱状图或点图。

为什么重要： - 当前已有 NGG-only / non-NGG-only 分析，但 per-PAM 更细，更能应对"是不是 shortcut"的追问。 - 如果 PAM 模型在 AGG/TGG/GGG/CGG 上表现一致，说明学到了"NGG 家族"的共性；如果只有 NGG 高、其他 NGG-like 都低，说明可能是 shortcut。

预期产出： - results/per_pam_metrics_with_shuffle.csv -

results/per_pam_metrics_with_shuffle.md -

results/figures/bl5_accuracy/per_pam_metric_plot.png/pdf

关键检查项： - NGG 家族 (AGG/TGG/GGG/CGG) 内部 AUPRC 是否一致 - Shuffle 控制在各 PAM 组上的崩溃程度是否均匀 - PAM-only 分析 (见 3.6) 可以与 per-PAM 结果交叉验证

【待插入】X 轴：PAM 分组 (AGG, TGG, GGG, CGG, non-NGG, rare) ; Y 轴：AUPRC; 四组柱状图分别对应 BL0b / NoPAM / PAM / Shuffle。需要能直观看出 PAM 模型在各 NGG 子类型上是否表现一致，以及 Shuffle 控制是否均匀崩溃。

3.3 bootstrap confidence interval

回答老师可能会问的： - 0.5313 比 0.5024 高 0.0289，这个稳不稳？ - 你的结果是撞出来的还是可重复的？

做什么： - 对 test set 做 **stratified bootstrap resampling** (保持 positive/negative 比例)，重复 1,000 次。

- 每次计算四模型的 AUROC 和 AUPRC。 - 计算 95% CI： - BL5-v4-PAM AUPRC: [L, U] - BL5-v4-NoPAM

AUPRC: [L, U] - 计算 **paired bootstrap**： - PAM - NoPAM AUPRC delta 的 95% CI - PAM - Shuffle AUPRC delta 的 95% CI - 如果 CI 不跨 0，说明差异统计显著。

为什么重要： - 单次 test AUPRC 是点估计。老师问"稳不稳"时，必须有 CI。 - +0.0289 看起来小，但如果 95% CI 是 [0.015, 0.042] 且不跨 0，就可以说"虽然绝对增量不大，但是统计显著的、可重复的"。

预期产出： - results/bootstrap_bl5_pam_vs_controls.csv -

results/bootstrap_bl5_pam_vs_controls.md -

results/figures/bl5_accuracy/bootstrap_auprc_ci.png/pdf

关键检查项： - PAM AUPRC 95% CI 宽度 (越窄越稳) - PAM - NoPAM delta 95% CI 是否包含 0 - PAM - Shuffle delta 95% CI 是否包含 0 (预期不包含)

【待插入】左图：1000 次 bootstrap 得到的 PAM / NoPAM / Shuffle AUPRC 分布直方图，标注 95% CI 边界；右图：PAM-NoPAM 和 PAM-Shuffle paired delta 的 bootstrap 分布，标注 95% CI 和是否跨 0。最关键的是右图——如果 PAM-NoPAM delta 的 95% CI 完全在 0 右侧，+0.0289 就是统计显著的。


3.4 threshold / top-k operating point 表

回答老师可能会问的：- 实际筛查时好不好用？- 如果实验室预算只够测前 1000 个位点，能找回多少 true positive?

Top-k evaluation: what happens if

1 Model scores all candidates

2 Sort by predicted r



Top-k directly matches limited validation budget

这张图怎么读（小白版）：

这张图用四步流程解释了"Top-k 评估"到底是什么意思，以及为什么它特别贴合实验室的真实场景。

想象你是一个做 wet lab 的研究生，老板给了你一笔预算，说"你只能测 1000 个候选位点，你给我挑最值得测的"。你怎么挑？Top-k 评估回答的就是这个问题。

- **Step 1: Model scores all candidates（模型给所有候选位点打分）** 模型对 test set 里的 95 万个位点逐一输出一个概率（例如 0.98, 0.91, 0.72...）。这个概率代表"模型认为这个位点是 true off-target 的信心"。
- **Step 2: Sort by predicted risk（按预测风险排序）** 把所有位点按概率从高到低排成一行。注意红点（observed_positive）应该尽量排在前面，蓝点（unobserved_candidate）尽量排在后面。模型的好坏就看它能不能做到这一点。
- **Step 3: Inspect top-k（只看前 k 个）** 由于预算有限，你只能 inspect 前 k 个。图中的 "top-k" 括号就是把最前面的 k 个位点圈出来。
- **Step 4: Count recovered observed_positive（统计找回了多少 true positive）** 在前 k 个里面，你数有多少个是红点（真的 observed_positive）。这引出两个关键指标：
 - **Precision@k** = 前 k 个里的红点个数 / k。代表"你测了 k 个，命中率是多少"。
 - **Recall@k** = 前 k 个里的红点个数 / 全部红点总数。代表"你把所有 true positive 找回来百分之多少"。

底部那句话是核心：**"Top-k directly matches limited validation budget: if we can test only k sites, which model gives the best shortlist?"** Top-k 直接对应有限的验证预算：如果我们只能测 k 个位点，哪个模型能给出最好的候选清单？

这就是为什么 AUPRC 虽然是个综合指标，但 Top-k 更能让老师感同身受——因为老师也关心"我的钱花在刀刃上了吗？"


做什么： - 基于已有的 test_predictions.csv，为每个模型生成 top-k operating point 表。 - k 取值：100, 500, 1000, 5000, 10000, 50000, 100000。 - 每个 (model, k) 报告：

- positives_recovered（找回的 observed positive 数）
- recall@k（占全部 3057 的比例）
- precision@k（positives_recovered / k）
- enrichment_over_random = precision@k / positive_rate（相比随机筛选富集了多少倍）

为什么重要： - 这种数字比单独 AUPRC 更容易打动老师。 - 例如：PAM 在 top 1000 找回 924 / 3057, recall $\approx 30.23\%$, precision $\approx 92.4\%$, enrichment $\approx 288\times$ 。这意味着实验室只需要测 0.1% 的候选位点，就能抓

回 30% 的 true positives。

预期产出： - 直接写入 results/figures/bl5_accuracy/topk_enrichment_summary.csv（已生成，需补充 enrichment_over_random 列） - results/figures/bl5_accuracy/topk_operating_table.md（PPT-ready 表格）



左图：前 1% 位点 ($k \approx 9,500$) PAM/NoPAM 即可召回 ~70% observed positives, 而 BL0b 仅 ~35%, Shuffle 仅 ~14%。

右图：前 100 个位点 Precision $\approx 100\%$, 前 1000 个位点 Precision $\approx 92\%$ 。这意味着实验室只需测 0.1% 的候选位点, 就能以 >90% 的精度抓回 30% 的 true positives。

关键检查项： - PAM vs NoPAM 在 top-1000 的 recall 差距 - Shuffle 在 top-10000 是否已经被 PAM 的 top-1000 超越 - enrichment_over_random 是否随 k 增加而单调下降 (验证排序质量)

3.4.1 Precision-Recall Trade-off 与实验室场景对照 (基于真实 test 数据)

本节直接回答老师最关心的问题: "如果实验室预算只够测 k 个位点, 能找回多少 true positive? 命中率是多少? 漏掉多少? 和随机抽相比强多少倍?" 所有数字均来自 results/figures/bl5_accuracy/topk_enrichment_summary.csv, test set n=954,326, total observed_positive=3,057。

随机基线： 由于 $\text{positive_rate} = 3,057 / 954,326 \approx 0.3203\%$, 随机抽取 k 个位点, 预期只命中 $k \times 0.3203\%$ 个 true positive。例如随机抽 1,000 个, 预期只中 **3.2** 个。

场景	k	PAM pos_recovered	PAM Recall	PAM Precision	BL0b Recall	BL0b Precision	富集倍数 (PAM)
高精度筛查	1,000	924 / 3,057	30.23%	92.40%	25.19%	77.00%	288.5×
中等规模	5,000	1,787 / 3,057	58.46%	35.74%	31.17%	19.06%	111.6×
较大规模	10,000	2,128 / 3,057	69.61%	21.28%	34.94%	10.68%	66.4×
高召回筛查	50,000	2,858 / 3,057	93.49%	5.72%	51.16%	3.13%	17.8×
接近全检	100,000	2,963 / 3,057	96.93%	2.96%	61.43%	1.88%	9.2×
随机基线	1,000	~3 / 3,057	0.32%	0.32%	0.32%	0.32%	1.0×

场景	k	PAM pos_recovered	PAM Recall	PAM Precision	BL0b Recall	BL0b Precision	富集倍数 (PAM)
----	---	----------------------	---------------	------------------	----------------	-------------------	---------------

逐项解读（把读者当小白）：

- 高精度筛查 (k=1,000)：**模型从 95 万个位点中挑出最可能的前 1,000 个。这 1,000 个里面，有 **924 个是真的 observed_positive**，命中率（Precision）高达 **92.4%**。但代价是只找回了全部 3,057 个 positive 中的 **30.2%**，还有约 2,133 个 true positive 被漏掉了。
- 对比 BL0b：**同样测 1,000 个，BL0b 只能找回 770 个，命中率 77%，**PAM 比 BL0b 多找回 154 个 true positive，命中率高出 15.4 个百分点。**
- 对比随机：**随机抽 1,000 个只能中 3.2 个，**PAM 的富集倍数是随机的 288.5 倍。**
- 中等规模 (k=5,000)：**把筛查范围扩大到前 5,000 个，找回的 true positive 增加到 1,787 个（Recall 58.5%），但命中率下降到 35.7%。这意味着每测 3 个位点，大约 1 个是对的、2 个是白测的。对于预算较宽裕的实验室，这个 operating point 可能是"性价比"最优的——找回了过半的 true positive，而假阳性成本尚可接受。
- 高召回筛查 (k=50,000)：**如果实验室的目标是把几乎所有 true positive 都找回来（例如临床前安全性评估），需要 inspect 前 50,000 个位点。此时 Recall 达到 **93.5%**，但 Precision 暴跌到 **5.7%**——每测 20 个位点，只有 1 个是对的，其余 19 个都是 unobserved_candidate。这就是老师说的"预测很多但只有少数对"的极端情况。
- 注意：**即便如此，**PAM 的 5.7% 仍然是随机基线 (0.32%) 的 17.8 倍**，模型远非无用，只是 operating point 选得太宽了。
- 接近全检 (k=100,000)：**inspect 前 10 万个位点，找回 2,963 个（Recall 96.9%），Precision 只有 2.96%。此时已经接近"把大半 test set 筛一遍"，失去了排序筛选的意义。

核心结论：

不存在一个 k 值能同时满足 **Precision > 90% 且 Recall > 90%**。在 top-1,000 处，模型非常"精"（Precision=92.4%）但不够"全"（Recall=30.2%）；在 top-50,000 处，模型非常"全"（Recall=93.5%）但不够"精"（Precision=5.7%）。实验室必须根据自身的验证预算和

假阳性容忍度，主动选择 operating point。

汇报话术（可直接用）：

"老师，我们的模型在 top-1,000 operating point 下，Precision 达到 92.4%，也就是说如果实验室只测前 1,000 个候选位点，命中率超过九成。但代价是只找回了 30% 的全部 true positive，会漏掉大约七成。如果实验室的预算更宽松，可以 inspect 前 5,000 个，此时命中率约 36%，但找回率提升到 58%。不存在一个阈值能同时满足高命中率和 high 找回率，这是所有排序模型的内在 trade-off。"

3.4.2 False Discovery Rate (FDR) 分析

本节回答："如果我测了 k 个位点，预期有多少是白测的（假阳性）？"

FDR (False Discovery Rate) = 1 - Precision。它和 Precision 是一枚硬币的两面。

k	PAM Precision	PAM FDR 含义
1,000	92.40%	7.6% 测 1,000 个，约 76 个是假阳性
5,000	35.74%	64.3% 测 5,000 个，约 3,213 个是假阳性
10,000	21.28%	78.7% 测 10,000 个，约 7,872 个是假阳性
50,000	5.72%	94.3% 测 50,000 个，约 47,142 个是假阳性

关键洞察： - 在 top-1,000 处，FDR 只有 7.6%，这意味着实验室每花 100 份测序钱，只有约 7~8 份是"冤枉钱"。
- 但如果把 k 放大到 50,000，FDR 飙升到 94.3%，几乎每测 20 个位点就有 19 个是白测的。 - **这不是模型变烂了，而是 operating point 选得太宽了。**模型的排序能力没变，只是你 inspect 的范围越大，尾部 noise 越多。

对比 BL0b： - BL0b 在 top-1,000 处的 FDR = 23.0% (Precision = 77.0%)，是 PAM 的 **3 倍**。 - 也就是说，用 BL0b 测 1,000 个位点，预期浪费 230 份测序钱；用 PAM 只浪费 76 份。**PAM 把 wet lab 的无效支出降低了约 67%。**

3.4.3 模型互补性：PAM ∪ BL0b 并集分析

本节回答："PAM 漏掉的那 70% true positive，能不能用另一个模型（比如 BL0b）找回来？两个模型取并集会怎么样？"

做法：对 test set 中的每个样本，取 PAM 和 BL0b 预测概率的较大值作为联合分数，然后重新排序取 top-k。计算并集找回的 observed_positive 数。

k	PAM alone Recall	BL0b alone Recall	PAM ∪ BL0b Recall	互补增益
1,000	30.23%	25.19%	32.68%	+2.45%
5,000	58.46%	31.24%	62.09%	+3.63%
10,000	69.61%	34.94%	73.05%	+3.43%
50,000	93.49%	51.13%	95.03%	+1.54%
100,000	96.93%	61.14%	97.81%	+0.88%

关键洞察： - 互补增益只有 **2~3 个百分点**，说明 BL0b 能找到的 true positive 绝大多数已经被 PAM 覆盖了。 - PAM 并不是"漏掉了 BL0b 能发现的独特信号"，而是 **PAM 本身就包含了 BL0b 的判别信息并做了增强**。 - 这也印证了文档的核心叙事：BL5-v4-PAM 是当前最强单一模型，late fusion（并集）带来的边际收益很小，不值得为了这 2~3% 的增益维护两个模型管线。

3.4.4 per-sgRNA 极端案例分析（Worst-case & Best-case）

本节回答："模型在最差的 sgRNA 上表现如何？有没有某个 sgRNA 上一个 true positive 都没找到？"

做法：把 test set 按 sgRNA 分组（共 72 个 test sgRNA），在每个 sgRNA 内部按 PAM 模型概率排序取 top-1,000，计算该 sgRNA 的 recall@1000。

PAM 模型 per-sgRNA recall@1000： - 均值：**97.66%** - 中位数：**100.00%** - 最低值：**75.00%** - 没有任何一个 sgRNA 的 recall 为 0%

Worst-5 sgRNA（按 recall@1000 排序）：

sgRNA_type	n_samples	n_positive	top-1,000 找回	recall
ATAGGAGAAGATGATGTATANGG	18,331	12	9	75.0%
GGGGGTTCCAGGGCCTGTCTNGG	14,111	537	426	79.3%
GCCTCTCCAGCCAGGGGCTGNNG	22,805	395	315	79.7%
GGCTGAGGAAGCTGAGGAGGNNG	45,848	26	22	84.6%
GCTGTGTTTGCGTCTCTCCCNNG	10,971	66	56	84.8%

关键洞察： - 即使是最差的 sgRNA（ATAGGAGAAGATGATGTATANGG），recall@1000 也达到 **75%**（12 个 true positive 找回了 9 个）。 - 超过半数的 sgRNA（中位数 = 100%）在 top-1,000 内就能找回 **全部** true positive。 - 这说明 PAM 模型的优势**不是集中在少数几个 sgRNA 上**，而是普遍分布在 72 个 test sgRNA 中。

对比 BL0b 的 per-sgRNA recall@1000： - 均值：**41.59%** - 中位数：**37.50%** - 最低值：**0.00%**（存在完全找不回的 sgRNA） - 最高值：**100.00%**

对比结论： BL0b 在某些 sgRNA 上完全失效（recall=0%），而 PAM 模型没有任何一个 sgRNA 是"死穴"。这进一步支持了 BL5-v4-PAM 作为阶段主结果的可靠性。

汇报话术（可直接用）：

"老师，您担心模型可能只在少数 sgRNA 上表现好，这是个非常关键的问题。我们计算了 72 个 test sgRNA 各自的 recall@1000，PAM 模型的中位数是 100%——意味着超过一半的 sgRNA 在前 1,000 个预测里就找回全部 true positive。最差的 sgRNA recall 也有 75%，没有任何一个 sgRNA 是完全失效的。相比之下，纯 RNA-FM baseline（BL0b）在某些 sgRNA 上 recall 直接为 0。这说明 PAM 模型的优势是普遍的，不是集中在少数几个 sgRNA 上的。"

第二优先级：做小型 baseline，不急着大训练

这一步用来排除"模型只是记住了训练集"或"模型只看 PAM"的质疑。训练成本极低（kNN 无训

练，PAM-only 是 tiny MLP）。

3.5 kNN / nearest-neighbor baseline

回答老师可能会问的： - 模型是不是只是记住了和训练集相似的样本？ - 换一个简单的非参数方法，能不能达到差不多的效果？

做什么： - 从训练集提取特征：RNA-FM CLS embedding (640-d) + LearnableRun (或简化为 off-target 序列的 one-hot / mismatch profile)。 - 对 test 样本，在 train 集中找 k 个最近邻 (k=5, 10, 50；距离度量 cosine / euclidean)。 - 预测概率 = 近邻中 positive 的比例，或近邻平均 read / label。 - 在 test set 上评估 AUROC / AUPRC。

为什么重要： - 如果 kNN 明显弱于 BL5-v4-PAM (例如 kNN AUPRC $\approx$ 0.25，而 PAM = 0.53)，你就可以说："模型不是简单查相似题，而是学到了超越局部相似性的判别模式。" - 如果 kNN 也达到 0.45+，说明特征空间本身已经高度结构化，此时应强调"特征工程 (RNA-FM + Run + PAM) 的价值大于 MLP 架构"。

预期产出： - results/knn_baseline_predictions.csv - results/knn_baseline_summary.json - results/knn_baseline_report.md

关键检查项： - kNN AUPRC vs BL0b / NoPAM / PAM 的相对位置 - k=5 vs k=50 的性能差异 (是否过平滑) - 使用不同特征组合 (仅 RNA-FM / RNA-FM+Run / RNA-FM+Run+PAM) 的 kNN 性能对比

【待插入】X 轴：模型 (kNN-k5 / kNN-k10 / kNN-k50 / BL0b / NoPAM / PAM)；Y 轴：AUPRC。需要能看出 kNN 显著低于 BL5-v4-PAM，证明模型不是简单查相似题。也可以画两张并排的 bar chart (左图 AUROC，右图 AUPRC)。

3.6 PAM-only baseline

回答老师可能会问的： - 只靠 PAM 本身能不能达到很高性能？ - 你的模型是不是其实只在看 PAM，其他特征都是摆设？

做什么： - 构建一个极简模型：PAM one-hot 或 PAM category embedding → tiny MLP（或直接 logistic regression）。 - **不使用 RNA-FM，不使用 Run，不使用 off-target 序列上下文。** - 在相同的 formal BL5 split 上训练和评估。

为什么重要： - 如果 PAM-only 很低（例如 AUPRC < 0.10），说明 BL5-v4-PAM 不是只看 PAM，PAM 只是整个证据链中的一环。 - 如果 PAM-only 也很高（例如 AUPRC > 0.30），那就说明 PAM shortcut 风险确实存在，解释时要更谨慎。这不是坏事，反而能让你的分析更可信。

预期产出： - results/pam_only_baseline_predictions.csv -

results/pam_only_baseline_summary.json - results/pam_only_baseline_report.md

关键检查项： - PAM-only AUPRC 与 Shuffle 控制的对比（Shuffle 也有 PAM 输入，但被打乱） - PAM-only 在 NGG vs non-NGG 上的表现差异 - 与 per-PAM 分析（3.2）交叉验证：如果 PAM-only 在各 PAM 组上的分布与 full model 一致，说明 PAM 是主导信号

【待插入】X 轴：模型（PAM-only / BL0b / NoPAM / PAM / Shuffle）；Y 轴：AUPRC。预期 PAM-only 远低于 PAM（例如 <0.15），证明序列上下文（RNA-FM + Run）提供了 PAM 之外的判别力。如果 PAM-only 反而很高，需要承认 PAM shortcut 风险。

第三优先级：解释性扰动

这是"模型是否符合生物直觉"的证据，比再堆一个 BL5-v5 更有解释价值。

3.7 in-silico perturbation

回答老师可能会问的： - 模型到底对 PAM、seed、连续错配有没有合理响应？ - 模型是符合生物学直觉，还是只是记住了统计关联？

做什么： 设计三类扰动，基于已训练好的 BL5-v4-PAM 模型做前向传播（不需要重新训练）：

扰动 A：固定 on_seq/off_seq 1-20，只替换 PAM - 对 test set 中每个样本，把 PAM 分别改成 AGG/TGG/GGG/CGG/NGG/NNN 等。 - 记录 probability 变化。 - 输出 PAM sensitivity score。

扰动 B：固定 PAM，只扰动 seed 区 mismatch - 在 positions 16-20 (hard seed) 上系统地引入/移除 mismatch。 - 观察 probability 是否随 seed mismatch 增加而上升（符合生物学：seed mismatch 越多，脱靶风险越高）。

扰动 C：固定 mismatch 数量，改变是否连续 run - 构造 synthetic 样本：相同 mismatch 数，但一种是 isolated mismatch，一种是 run2/run3+。 - 观察模型是否对连续错配赋予更高权重（符合 ConMismatch9 的先验假设）。

为什么重要： - 当前证据是"Shuffle 控制崩了"（否定性证据：PAM 不能乱）。扰动提供**肯定性证据**：PAM Encoder 具体对哪种信号敏感、对哪种不敏感。 - 如果 seed mismatch 增加 → probability 单调上升，说明模型学到了合理的生物学规律；如果杂乱无章，说明模型可能只是在 memorizing。

预期产出： - results/insilico_perturbation/pam_sensitivity.csv -
results/insilico_perturbation/seed_mismatch_response.csv -
results/insilico_perturbation/run_state_response.csv -
results/figures/bl5_accuracy/insilico_pam_perturbation_heatmap.png/pdf -
results/figures/bl5_accuracy/insilico_seed_run_response.png/pdf

关键检查项： - PAM 扰动是否单调：NGG 家族 > non-NGG > NNN（或类似合理序） - Seed mismatch 响应是否单调递增 - Run3+ 的 probability 是否高于 isolated mismatch（相同总 mismatch 数下）

【待插入】X 轴：原始 PAM；Y 轴：扰动后 PAM；颜色：平均 probability 变化。对角线（原始=扰动后）应为 0，NGG→NGG 附近应为深蓝（高概率），NGG→NNN 应为深红（概率下降）。

【待插入】左图：固定 PAM，seed mismatch 数从 0→5 时 probability 的响应曲线（预期单调上升）；右图：固定总 mismatch 数，isolated vs run2 vs run3+ 的 probability 对比（预期

run3+ > run2 > isolated) 。

第四优先级：训练稳定性

这一步需要 GPU，但很重要。现有数据已经提示训练波动：原始 PAM AUPRC=0.5313，两卡重跑 AUPRC=0.5161，差了 0.0152。

3.8 BL5-v4-PAM 多 seed 重复

回答老师可能会问的： - 你的结果是撞出来的还是稳出来的？ - 换种子还能复现吗？

做什么： - 用 **3 个不同的随机种子** (seed 42, 43, 44) 重新训练 BL5-v4-PAM。 - 保持 config、split、硬件环境完全相同。 - 记录每次的：test AUROC、AUPRC、best epoch、训练时间、最终 loss。 - 计算 mean $\pm$ std，画 error bar 图。

为什么重要： - 当前已有两个数据点：原始 run (0.5313) 和 2GPU 重跑 (0.5161)，差值 0.0152。不算崩，但说明存在训练波动。 - 如果 3 个 seed 的 AUPRC 分别是 0.531, 0.528, 0.535 (std < 0.004)，结果非常稳健。 - 如果是 0.531, 0.516, 0.550 (std > 0.015)，说明模型对初始化敏感，需要调优（降低学习率、增加 early stopping、调 focal loss gamma）后才能作为"主结果"。

预期产出： - results/bl5_v4_pam_multi_seed/summary.csv -
results/bl5_v4_pam_multi_seed/seed42_summary.json -
results/bl5_v4_pam_multi_seed/seed43_summary.json -
results/bl5_v4_pam_multi_seed/seed44_summary.json -
results/figures/bl5_accuracy/multi_seed_stability.png/pdf

关键检查项： - 3 seeds AUPRC mean $\pm$ std - AUPRC std < 0.01 (通过标准)；0.01~0.02 (可接受但需说明)；> 0.02 (不稳定，需调优) - best epoch 是否一致 (如果 seed 43 在 epoch 3 就停，seed 42 在 epoch 9，说明早停策略过敏感)

【待插入】X 轴：模型（BL0b / NoPAM / PAM / Shuffle）；Y 轴：AUPRC；每个模型 3 个 seed 的点 + mean error bar。PAM 的 3 个点应密集聚集（std 小），Shuffle 的点也应稳定地低。如果 PAM 的 error bar 很大，说明主结果不稳定，需要调优后再封口。

4. Phase 2：路线完整性补充（BL4-full）

4.1 为什么补 BL4-full

BL4-full 的定义是：**RNA-FM + Region + Run 三者拼接**。当前项目中：- BL4-Run-only 已跑（AUPRC = 0.206, CCLMoff group-safe），但这是旧结果，且 split 可能不是 formal BL5 split。- **BL4-full (Region + Run + RNA-FM)** 从未在 formal BL5 split 上实现和评估。

BL4-full 的科学价值是：验证"显式生物先验（Region + Run）能否增强 frozen RNA-FM"。如果 BL4-full 的 AUPRC 显著低于 BL5-v4-PAM，说明：- BL5-v4 的 LearnableRun + PAM 架构优于简单的 Region+Run+FM 拼接；或者 - fine-tuned RNA-FM 比 frozen RNA-FM 强很多（但 BL0b 已经是 fine-tuned，所以这个对照需要仔细设计）。

4.2 实施建议（低优先级，视老师要求）

- 如果老师问"你有没有试过把三种特征都拼起来？" → 需要补 BL4-full。
 - 如果老师没问 → 可以暂时不补，先把 BL5-v4-PAM 封口工作做完。
 - BL4-full 的实现相对简单（复用现有 Region Encoder、Run Encoder、RNA-FM Encoder，concat 后接 MLP），预计 1~2 天可完成训练和评估。
-

5. Phase 3：BL6 的时机与前提

5.1 BL6 的准入条件

以下全部满足后，方可启动 BL6：

- 1. BL5-v4-PAM 封口工作完成（Phase 1 八项全部做完，文档齐备）。
- 2. BL4-full 已完成或已明确不需要（老师未质疑路线完整性）。
- 3. BL5-v4-PAM 的多 seed 稳定性验证通过（AUPRC std < 0.01）。
- 4. 老师在组会上认可"BL5-v4-PAM 是阶段主结果"，并主动提出"下一步能不能做更复杂的交互？"
- 5. 有充分的 GPU 资源和开发时间（BL6 的训练和调参成本显著高于 BL5-v4）。

5.2 BL6 的风险控制

如果启动 BL6，必须： - 保留 BL5-v4-PAM 的 checkpoint 和 config 作为强 baseline。 - BL6 的每个子版本（例如单层 Cross-Attn、多层 Cross-Attn、不确定性感知）都要有独立的 NoPAM / shuffle 控制。 - 不跳过 BL5-3（Cross-Attn + Gated），BL6 必须在 BL5-3 的代码基上开发。

6. 推荐时间线（以 2 周为一个冲刺周期）

周次	任务	优先级	预估时间	是否需要 GPU
W1	3.1 per-sgRNA + 3.2 per-PAM	P0	2~3 天	
W1	3.3 Bootstrap CI + 3.4 top-k 表	P0	1~2 天	
W2	3.5 kNN baseline + 3.6 PAM-only	P1	2~3 天	(kNN 无训练) / ⚠ (PAM-only 小训练)
W2~W3	3.7 in-silico perturbation	P2	2~3 天	(前向传播 only)
W3~W4	3.8 多 seed 稳定性 (seed 42/43/44)	P0	4~5 天	
W4~W5	组会汇报、根据反馈调整	P0	2~3 天	—
W5+	视老师要求补 BL4-full	P2	2~3 天	
W7+	满足 5.1 条件后，启动 BL6	P3	—	

总封口周期：约 4~5 周（含 GPU 训练等待时间）。

7. 风险与应对

风险	可能性	影响	应对
per-sgRNA AUPRC 波动大	中	高	汇报时强调"整体 AUPRC 稳健，个别 sgRNA 因样本稀疏导致方差大"，并提供 sgRNA-level bootstrap CI。
PAM – NoPAM delta 的 Bootstrap CI 跨 0	低	高	若 CI 包含 0，说明 +0.0289 可能不显著。此时需增加训练数据量、或调整 PAM Encoder 结构、或承认"PAM 贡献较小但方向一致"。
kNN 接近 MLP 性能	低	中	若 kNN AUPRC ≈ 0.50 ，说明特征空间高度结构化，应强调"特征工程（RNA-FM + Run + PAM）比 MLP 架构更重要"。
PAM-only baseline 也很高	中	中	若 PAM-only AUPRC > 0.30 ，承认 PAM 是强信号，但强调"完整模型仍显著优于 PAM-only，说明序列上下文提供了额外判别力"。
多 seed 不稳定 (std > 0.02)	中	高	优先调优（降低学习率、增加 early stopping、调 focal loss gamma），而非直接进 BL6。
老师要求立刻做 BL6	中	高	用本文档作为论据："BL5-v4-PAM 的证据链已完整，但封口工作尚未完成。建议先花 2~3 周把主结果讲稳，再进 BL6，否则 BL6 的增益无法与稳定的 BL5-v4 对比。"

8. 附录：关键图件索引

图号	文件名	存放路径	核心信息
Fig 1	fig1_leaderboard_auprc_auroc.png	reborn_doc/pic/	四模型 AUROC/AUPRC 总览
Fig 2	fig2_precision_recall_curves.png	reborn_doc/pic/	PR 曲线标准学术对比
Fig 3	fig3_auprc_contribution_waterfall.png	reborn_doc/pic/	最推荐主图 ：AUPRC 增量瀑布

图号	文件名	存放路径	核心信息
	g		
Fig 4	fig4_topk_enrichment.png	reborn_doc/pic/	Top-k 召回与 Precision，回答落地价值
Fig 5	fig5_stratified_metrics.png	reborn_doc/pic/	NGG / non-NGG 分层指标
Fig 6	fig6_paired_delta.png	reborn_doc/pic/	PAM vs Shuffle 的 paired delta，机制证据

待补充图件（本文档 Phase 1 执行后生成，当前为占位符）：

图号	预期文件名	存放路径	状态	核心信息
Fig 7	per_sgrna_delta_plot.png	results/figures/ bl5_accuracy/	待画	per-sgRNA AUPRC 与 delta 分布
Fig 8	per_pam_metric_plot.png	results/figures/ bl5_accuracy/	待画	per-PAM motif AUPRC 对比
Fig 9	bootstrap_auprc_ci.png	results/figures/ bl5_accuracy/	待画	Bootstrap 95% CI
Fig 10	insilico_pam_perturbation_heatmap.png	results/figures/ bl5_accuracy/	待画	PAM 扰动热力图
Fig 11	insilico_seed_run_response.png	results/figures/ bl5_accuracy/	待画	Seed / Run 扰动响应
Fig 12	multi_seed_stability.png	results/figures/ bl5_accuracy/	待画	多 seed AUPRC error bar

图号	预期文件名	存放路径	状态	核心信息
Fig 13	knn_baseline_comparison.png	results/figures/bl5_accuracy/	待画	kNN baseline 对比
Fig 14	pam_only_baseline_comparison.png	results/figures/bl5_accuracy/	待画	PAM-only baseline 对比

说明： Fig 1~6 已由现有实验数据生成并插入正文。 Fig 7~14 需要基于后续分析数据绘制。 请将图片放入 `results/figures/bl5_accuracy/` 目录下，文档中的相对路径引用会自动生效。

9. 结论

当前项目处于**"最强模型已跑出，但故事尚未讲稳"**的关键节点。BL5-v4-PAM (AUPRC=0.5313) 已经是 formal BL5 split 上的阶段冠军，且 NoPAM / shuffle / NGG 分层 / paired analysis 形成了完整的证据链。

最优先行动： 不是继续追模型复杂度，而是把现在这个结果从"看起来赢了"推进到"经得住追问"。

具体而言： 1. 先做第一优先级 (per-sgRNA、per-PAM、bootstrap CI、top-k 表) —— 不需要训练，直接增强答辩能力。 2. 再做第二优先级 (kNN、PAM-only) —— 排除质疑，夯实可信度。 3. 接着做第三优先级 (in-silico perturbation) —— 提供机制解释。 4. 最后做第四优先级 (多 seed 重复) —— 验证训练稳定性。 5. 视老师反馈补 BL4-full。 6. 全部满足后再考虑 BL6。

中文决策版： 当前不要开 BL6。当前不要继续堆 BL5 新架构。优先封口 BL5-v4-PAM：先做不需要训练的验证分析 (per-sgRNA、per-PAM、bootstrap CI、top-k 表)，再做小型 baseline (kNN、PAM-only)，再做解释性扰动，最后做多 seed 稳定性。然后视老师要求补 BL4-full。最后再考虑 BL6。